

1.

(a)

주어진 분포의 likelihood function은 l 이라고 하면

$$l(\mu_i | y_{i1}, y_{i2}, \dots, y_{iJ}) = \prod_{j=1}^J \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y_{ij}-\mu_i)^2}{2\sigma^2}\right) \quad \text{if } y_{ij}'s \text{ are independent}$$

$$L := \log l$$

$$L(\mu_i | y_{i1}, y_{i2}, \dots, y_{iJ})$$

$$= \log \prod_{j=1}^J \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y_{ij}-\mu_i)^2}{2\sigma^2}\right)$$

$$= \sum_{j=1}^J \log \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y_{ij}-\mu_i)^2}{2\sigma^2}\right)$$

$$= J \log \frac{1}{\sqrt{2\pi}\sigma} - \sum_{j=1}^J \frac{(y_{ij}-\mu_i)^2}{2\sigma^2}$$

$$\frac{\partial L}{\partial \mu_i} = \frac{1}{\sigma^2} \sum_{j=1}^J (y_{ij} - \mu_i) \stackrel{\text{set}}{=} 0$$

$$\Rightarrow \sum_{j=1}^J y_{ij} = J\mu_i \quad \dots \textcircled{1}$$

$$\frac{\partial^2 L}{\partial \mu_i^2} = -\frac{J}{\sigma^2} < 0 \quad \dots \textcircled{2}$$

By ① & ②, $\hat{\mu}_i^{\text{MLE}} = \frac{1}{J} \sum_{j=1}^J y_{ij} = \bar{y}_i$ for $i=1, \dots, I$

(b)

 $y = X\mu + \varepsilon$, $y \in \mathbb{R}^n$, $\varepsilon \in \mathbb{R}^n$, $\mu \in \mathbb{R}^I$ 에서식이 성립하기 위한 X 의 차원은 $X \in \mathbb{R}^{n \times I}$ 이때 one-way anova에서의 design matrix X 는 다음과 같다.

$$X = \begin{bmatrix} 1 & 0 & \dots & 0 \\ 1 & 0 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \\ 0 & 0 & \dots & 1 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{bmatrix}$$

여기에서 X 는 각각의 observation이 어떤 group에 속해 있는지 나타낸다.

μ :의 OLS estimator는 아래와 같이 계산된다.

$$\hat{\mu} = \underset{\mu}{\operatorname{argmin}} (y - X\mu)^T (y - X\mu) \quad (\mu = (\mu_1, \mu_2, \dots, \mu_I))$$

$$S(\mu) := (y - X\mu)^T (y - X\mu)$$

$$\frac{\partial S(\mu)}{\partial \mu} = \frac{\partial}{\partial \mu} (y^T y - \mu^T X^T y - y^T X \mu + \mu^T X^T X \mu)$$

$$= \frac{\partial}{\partial \mu} (-2\mu^T X^T y + \mu^T X^T X \mu)$$

$$= -2X^T y + 2X^T X \mu \xrightarrow{\text{set}} 0$$

$$2X^T X \mu = 2X^T y \Rightarrow (X^T X)\mu = X^T y$$

$$\Rightarrow (X^T X)^{-1}(X^T X)\mu = (X^T X)^{-1}X^T y$$

$\therefore \hat{\mu} = (X^T X)^{-1}X^T y$ (\because 위에서 X 의 column들이 independent하다는 것을 알 수 있다. $\Rightarrow X^T X$ is invertible.)

$$X^T X = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 1 & \cdots & 0 \\ 0 & 0 & \cdots & 1 \\ 0 & 0 & \cdots & 1 \end{bmatrix}^T \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 1 & \cdots & 0 \\ 0 & 0 & \cdots & 1 \\ 0 & 0 & \cdots & 1 \end{bmatrix} = \begin{bmatrix} J & 0 & \cdots & 0 \\ 0 & J & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & J \end{bmatrix}$$

$$(X^T X)^{-1} = \begin{bmatrix} \frac{1}{J} & 0 & \cdots & 0 \\ 0 & \frac{1}{J} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \frac{1}{J} \end{bmatrix}$$

$$X^T y = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 1 & \cdots & 0 \\ 0 & 0 & \cdots & 1 \\ 0 & 0 & \cdots & 1 \end{bmatrix}^T \begin{bmatrix} y_{11} \\ \vdots \\ y_{1J} \\ y_{21} \\ \vdots \\ y_{2J} \\ \vdots \\ y_{I1} \\ \vdots \\ y_{IJ} \end{bmatrix} = \begin{bmatrix} y_{11} + \cdots + y_{1J} \\ y_{21} + \cdots + y_{2J} \\ \vdots \\ y_{I1} + \cdots + y_{IJ} \end{bmatrix}$$

$$(X^T X)^{-1} X^T y = \begin{bmatrix} \frac{1}{J} & 0 & \cdots & 0 \\ 0 & \frac{1}{J} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \frac{1}{J} \end{bmatrix} \begin{bmatrix} \sum_{j=1}^J y_{1j} \\ \vdots \\ \sum_{j=1}^J y_{2j} \\ \vdots \\ \sum_{j=1}^J y_{Ij} \end{bmatrix} = \begin{bmatrix} \bar{y}_1 \\ \bar{y}_2 \\ \vdots \\ \bar{y}_I \end{bmatrix}$$

(c)

Fitted value of y denoted by \hat{y} is

$$\hat{y} = X\hat{\mu} = X(X^T X)^{-1} X^T y$$

$$\therefore P_x = X(X^T X)^{-1} X^T$$

$$= \begin{bmatrix} 1 & 0 & \dots & 0 \\ -1 & 0 & \dots & 0 \\ \vdots & \ddots & \ddots & \vdots \\ -1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ 0 & 0 & \dots & 0 \\ \vdots & \ddots & \ddots & \vdots \\ 0 & 0 & \dots & 0 \end{bmatrix} \begin{bmatrix} \frac{1}{5} & 0 & \dots & 0 \\ 0 & \frac{1}{5} & \dots & 0 \\ \vdots & & \ddots & \vdots \\ 0 & 0 & \dots & \frac{1}{5} \end{bmatrix} \begin{bmatrix} 1 & 0 & \dots & 0 \\ -1 & 0 & \dots & 0 \\ \vdots & \ddots & \ddots & \vdots \\ -1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ 0 & 0 & \dots & 0 \\ \vdots & \ddots & \ddots & \vdots \\ 0 & 0 & \dots & 0 \end{bmatrix}^T = \begin{bmatrix} \frac{1}{5} & 0 & \dots & 0 \\ \frac{1}{5} & 0 & \dots & 0 \\ \vdots & \ddots & \ddots & \vdots \\ \frac{1}{5} & 0 & \dots & 0 \\ 0 & \frac{1}{5} & \dots & 0 \\ 0 & \frac{1}{5} & \dots & 0 \\ \vdots & \ddots & \ddots & \vdots \\ 0 & \frac{1}{5} & \dots & 0 \\ 0 & 0 & \dots & \frac{1}{5} \\ 0 & 0 & \dots & \frac{1}{5} \\ \vdots & \ddots & \ddots & \vdots \\ 0 & 0 & \dots & \frac{1}{5} \end{bmatrix}^T$$

$$= \begin{bmatrix} \frac{1}{5} & \dots & \frac{1}{5} & 0 & \dots & 0 & 0 & \dots & 0 \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ \frac{1}{5} & \dots & \frac{1}{5} & 0 & \dots & 0 & 0 & \dots & 0 \\ 0 & \dots & 0 & \frac{1}{5} & \dots & \frac{1}{5} & 0 & \dots & 0 \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & \dots & 0 & \frac{1}{5} & \dots & \frac{1}{5} & 0 & \dots & 0 \\ \vdots & & \vdots & \vdots & & \ddots & \vdots & & \vdots \\ 0 & \dots & 0 & 0 & \dots & 0 & \frac{1}{5} & \dots & \frac{1}{5} \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & \dots & 0 & 0 & \dots & 0 & \frac{1}{5} & \dots & \frac{1}{5} \end{bmatrix} \quad \text{(J)}$$

(d)

Fitted value of y

$$\hat{y} = P_X y = X(X^T X)^{-1} X^T y$$

$$= \begin{bmatrix} \frac{1}{5} & \dots & \frac{1}{5} & 0 & \dots & 0 & 0 & \dots & 0 \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ \frac{1}{5} & \dots & \frac{1}{5} & 0 & \dots & 0 & 0 & \dots & 0 \\ 0 & \dots & 0 & \frac{1}{5} & \dots & \frac{1}{5} & 0 & \dots & 0 \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & \dots & 0 & \frac{1}{5} & \dots & \frac{1}{5} & 0 & \dots & 0 \\ \vdots & & \vdots & & & \ddots & \vdots & & \vdots \\ 0 & \dots & 0 & 0 & \dots & 0 & \frac{1}{5} & \dots & \frac{1}{5} \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & \dots & 0 & 0 & \dots & 0 & \frac{1}{5} & \dots & \frac{1}{5} \end{bmatrix} \begin{bmatrix} y_{11} \\ y_{12} \\ y_{21} \\ y_{22} \\ \vdots \\ y_{n1} \\ y_{n2} \end{bmatrix} = \begin{bmatrix} \bar{y}_1 \\ \bar{y}_2 \\ \vdots \\ \bar{y}_n \end{bmatrix}$$

$$\hat{e} = y - \hat{y} = y - P_X y = (I - P_X) y$$

$$= \begin{bmatrix} y_{11} - \bar{y}_1 \\ \vdots \\ y_{12} - \bar{y}_1 \\ y_{21} - \bar{y}_2 \\ \vdots \\ y_{22} - \bar{y}_2 \\ \vdots \\ y_{n1} - \bar{y}_n \\ \vdots \\ y_{n2} - \bar{y}_n \end{bmatrix}$$

(e)

문제에서 언급되었듯이 MS_{trt} 와 MSE 가 independent함을 보이는 것은

SS_{trt} 와 SSE 가 independent함을 보이는 것과 동일하다.

ANOVA Decomposition이 성립하는지 확인함으로써, 즉

$$SST = \|y - \bar{y}\|_2^2 = \|y - \hat{y} + \hat{y} - \bar{y}\|_2^2$$

$$= \|y - \hat{y}\|_2^2 + \|\hat{y} - \bar{y}\|_2^2 + 2(y - \hat{y})^T(\hat{y} - \bar{y})$$

$$= SSE + SS_{\text{trt}} + 2(y - \hat{y})^T(\hat{y} - \bar{y}) \text{ 이서}$$

$$(y - \hat{y})^T(\hat{y} - \bar{y}) = 0 \Rightarrow (y - \hat{y}) \text{ 와 } (\hat{y} - \bar{y}) \text{ 이 orthogonal함을 보임으로써}$$

↓ ↓
residual treatment (\because 이 경우에서는 \hat{y} 가 \bar{y} 들의 vector이므로)

SS_{trt} 와 SSE 가 independent함을 알 수 있다. 주어진 상황에 적용 가능)

$$(y - \hat{y})^T(\hat{y} - \bar{y})$$

$$= (y - P_x y)^T(P_x y - \bar{y})$$

$$= y^T P_x y - y^T P_x^T P_x y - y^T \bar{y} + y^T P_x^T \bar{y} \quad (\because P_x \text{ is idempotent and symmetric, 증명은 하단에})$$

$$= y^T P_x y - y^T P_x y - y^T \bar{y} + y^T P_x^T \bar{y} \quad (\because P_x \text{ is symmetric})$$

$$= y^T P_x \bar{y} - y^T \bar{y}$$

$$= y^T P_x \bar{y} - y^T P_x \bar{y} \quad (\because \bar{y} = P_x \bar{y}, \text{ by Figure 1})$$

$$= 0$$

$$\text{cf) } P_x P_x = X(X^T X)^{-1} X^T X (X^T X)^{-1} X^T$$

$$= X(X^T X)^{-1} X^T$$

$$= P_x$$

$$P_x^T = \{X(X^T X)^{-1} X^T\}^T$$

$$= X \{(X^T X)^{-1}\}^T X^T$$

$$= X(X^T X)^{-1} X^T$$

$$= P_x$$

(f)

STAT409_Midterm_2021320322.R에 과정 첨부

결과

$MStrt = 11.701$

$MSE = 1.338$

$F = 8.746$





Figure 1


2.
(a)

STAT409_Midterm_2021320322.R에 과정 첨부



(b)

STAT409_Midterm_2021320322.R에 과정 첨부



(c)


2-(b)의 결과에서 확인할 수 있듯이, polynomial의 차수가 높아질수록 R-squared가 단순히 커지고 있는 경향을 볼 수 있다. 즉, 모형이 복잡할수록 R-squared는 계속해서 커지기만 할 것이다. 이러한 경우 polynomial의 차수가 증가함에 따라 모형이 training set에 더 육 친화적이게 적합이 되기 때문에 training-error는 계속해서 감소하게 될 것이다. 그러나 R-squared를 model selection의 지표로 결정한다면 단순히 복잡한 모형을 선호하게 된다는 것과 같다. 모형이 복잡할수록 bias는 감소하겠지만 variance는 증가할 것이고 모형의 일반화 성능이 감소하게 될 것이다. 종합적으로 R-squared를 model selection의 지표로 사용되기에 적절하지 않다.

(d)

STAT409_Midterm_2021320322.R에 과정 첨부
BIC에 근거했을 때 $p = 5$ 인 모델을 선택한다.

(e)

STAT409_Midterm_2021320322.R에 과정 첨부




(f)

STAT409_Midterm_2021320322.R에 과정 첨부


Tuning의 기준은 BIC로 결정하였다.

BIC에 근거했을 때 df = 5인 모델을 선택한다.

Training set



Testing set




(g)

STAT409_Midterm_2021320322.R에 과정 첨부


Tuning의 기준은 BIC로 결정하였다.

BIC에 근거했을 때 df = 5인 모델을 선택한다.

Training set



Testing set



(h)

2-(g)에서 fitting한 B-spline median regression model을 가장 좋은 모형이라고 생각할 수 있다. B-spline regression 특성상 자유도를 직접 조정할 수 있기 때문에 overfitting을 더욱 효과적으로 방지할 수 있다. 또한 B-spline regression은 계산적인 면에서 안정적이다. 그리고 scatter plot을 보았을 때 곳곳에 outlier로 의심되는 observation들이 있다. median regression은 mean regression에 비해서 outlier에 robust하다는 장점이 있기 때문에 주어진 데이터셋과 같은 데이터를 적합할 때 유용하게 사용할 수 있다.
이러한 면에서 B-spline regression의 장점과 median regression의 장점을 모두 가진 B-spline median regression model을 가장 좋은 모형으로 선택할 것을 고려할 수 있다.

정량적인 지표를 알아보기 위하여 testing error를 확인해 보았다.

(STAT409_Midterm_2021320322.R에 과정 첨부)

B-spline median regression에서의 testing error가 가장 낮게 측정된 것을 확인할 수 있었고, 이것을 근거로 B-spline median regression을 가장 좋은 모형으로 선택한다.